

Notas de arquitectura

Siete complementos a la vista de resumen, para que la arquitectura llegue a la conversación con los sponsor respondiendo también cómo se sabe que acierta, cuánta decisión tiene entregada y qué ocurre cuando se equivoca.

SURA Colombia · Transformación prestación y reclamaciones, MVP autorizaciones de salud

Elaborado por Tech and Solve para SURA · Septiembre de 2026

Elaborado sobre la vista de resumen de la arquitectura de gestores, en su versión del 2 de septiembre de 2026.

Objetivo

QUÉ QUEREMOS QUE QUEDE ACORDADO

Qué siete piezas conviene hacer visibles en la vista de resumen para que sostenga la presentación a los sponsor, y en qué orden agregarlas sin frenar la construcción.

La vista de resumen que el equipo viene refinando responde con precisión la pregunta de qué hace el sistema: cuatro gestores con sus capas, los agentes de cada capa, los tres puntos donde se decide y las bandejas donde entra una persona. Para una presentación a sponsor, esa mitad ya está.

La otra mitad es la que un comité de patrocinadores pregunta a continuación, y son siete preguntas que la vista todavía no tiene dónde responder. La primera de todas es la actividad de los agentes, que es el término con el que el equipo la nombra en su propio seguimiento. De esa lectura salen siete complementos. Ninguno cambia el flujo dibujado ni redistribuye responsabilidades entre gestores: cada uno agrega a la vista una pieza que ya está en el diseño del equipo o en las notas de esta serie, y que hoy no aparece en el resumen. Son sugerencias: cada una se puede tomar, ajustar o descartar sin que se caigan las demás.

Cada complemento se lee en una página y dice lo mismo en el mismo orden: qué habilita, qué problema ataca, cómo se ve, qué cuesta, cómo se verifica y qué acuerdos requiere. Al final está la vista con los siete ubicados, la secuencia recomendada y el mapa de qué de la vista actual cubre cada uno.

Qué no proponemos

- No proponemos cambiar la arquitectura dibujada. Las tres capas por gestor, el reparto en paralelo hacia los extractores y la separación entre reglas duras y modelo experto se mantienen tal como están.
- No proponemos una vista nueva. Los siete complementos son adiciones sobre la que ya existe, y el criterio para incluir cada uno fue que responda una pregunta que el sponsor va a hacer.
- No proponemos una plataforma nueva: todo se conecta al AI Control Plane, a la torre de control y al almacén de eventos que ya están en el diseño del equipo.
- No proponemos frenar la construcción. Cinco de los siete son trabajo dentro de cada gestor mientras se construye, no un proyecto aparte.
- No proponemos un comité de aprobación. Ninguno de los siete introduce un permiso que haya que pedir.

Lo que la vista ya sostiene

Conviene empezar por ahí, porque es lo que hace que los siete complementos sean adiciones y no correcciones. Estas seis decisiones ya están tomadas en la vista y las seis nos parecen correctas:

Tres capas, con los mismos nombres en dos gestores

Entrada y salida, expertos y auditoría se repiten en Solicitud y en Evaluación. Esa repetición es lo que permite que el patrón se reusa en los gestores que faltan, en lugar de que cada uno invente su propia estructura.

Reglas duras separadas del modelo experto

La caché de reglas duras y el modelo experto están dibujados como piezas distintas dentro de la capa de evaluación. Es la separación entre lo que debe ser determinístico y lo que admite juicio, y es la que permite que una negación se sustente en reglas versionadas.

Una persona al final de los dos caminos que pesan

La revisión humana de evaluación y la bandeja de autorizaciones-convenios están nombradas, con su condición de entrada. Nombrar una bandeja es definir un estado y su dueño, y en coordinación eso ya está hecho.

Reparto en paralelo hacia los extractores

El enrutador abre hacia cuatro expertos por documento. Esa decisión convierte la latencia del gestor en la del documento más lento y no en la suma de todos, que es la mitigación conocida del patrón jerárquico.

Una API orquestadora por tipo de solicitud, en los tres gestores

Es el nivel alto de la jerarquía: interpreta la solicitud, determina el tipo y decide qué se necesita. Que el tipo de solicitud sea explícito desde la entrada es lo que después permite declarar umbrales y autonomía por tipo de caso, en lugar de una sola constante por agente.

El generador de evento, declarado

La convención de elementos distingue componente agéntico, sistema de reglas experto, generador de evento y API. La cuarta pieza que falta dibujar es a dónde van esos eventos, y es el primer complemento.

Figura 1. La vista de resumen, tal como la leemos



Trazo continuo: dibujado con detalle en la vista.
Trazo punteado: presente como bloque, sin contenido interno todavía.
En ámbar, los dos lugares donde una decisión automática cierra el camino.

Reconstrucción de la vista de resumen. Los cuatro gestores con contenido concentran el detalle; la banda de la torre y los dos gestores del cierre están presentes como bloque.

LA LECTURA, EN UNA FRASE

La vista responde muy bien qué hace el sistema. Las siete preguntas que siguen son de otra naturaleza: cómo se sabe que lo hace bien, y qué pasa cuando no. Ninguna de las siete cambia el flujo dibujado.

Las siete preguntas, y dónde se responden

Este es el criterio con el que elegimos los siete complementos. Cada uno existe porque responde una pregunta concreta que un comité de patrocinadores hace sobre un sistema que decide solo, y porque hoy la vista no tiene dónde responderla.

Lo que va a preguntar el sponsor	Complemento	Esfuerzo
¿Dónde vemos, en una pantalla, cómo va todo esto?	C1	Medio
¿Cómo sabemos que el agente acierta, y no solo que responde? Es decir, su acertividad.	C2	Bajo
¿El sistema se modifica solo? ¿Quién aprueba ese cambio?	C3	Medio
¿Cuánto está decidiendo sin nosotros, y cómo se lo quitamos?	C4	Bajo
¿Qué pasa cuando se equivoca con la solicitud de un asegurado?	C5	Bajo
¿Quién controla qué le está permitido, y dónde queda el dato clínico?	C6	Bajo
¿Esto nos baja la glosa y el fraude, o solo nos acelera?	C7	Medio

NUESTRA RECOMENDACIÓN DE ORDEN

C1 y C2 primero, y en ese orden, porque son los únicos cuya oportunidad se pierde: la evidencia que no se captura mientras el gestor se construye no se recupera después. C5 y C6 se pueden resolver en la vista esta semana, porque son sobre todo nombres y un plano que ya existe. C3 y C4 llegan cuando haya con qué medir, y C7 cuando exista el lago de datos.

Los siete complementos

C1 Bus de eventos, y la torre con contenido

Esfuerzo medio

Antes de que el segundo gestor emita

QUÉ SE PODRÁ AFIRMAR DESPUÉS Y HOY NO

Dónde está cada solicitud, cuánto lleva esperando y qué se va a vencer, en una sola pantalla y para los seis gestores.

Qué problema ataca

La convención de elementos de la vista ya declara el generador de evento, pero la vista no muestra por dónde viajan esos eventos ni quién los consume, y la banda de la torre de control aparece con su front y su back sin nada que la alimente. Para el resto de la vista eso no estorba; para la presentación sí, porque la torre es la respuesta a la primera pregunta que recibe un sponsor, y ahora mismo está dibujada como encabezado y no como destino.

Cómo se ve

- El bus compartido dibujado explícitamente, con la torre suscrita a la totalidad de los eventos, tal como el equipo lo definió en sus requisitos técnicos, y no a un subconjunto negociado gestor por gestor.
- Un evento por cada cambio de estado, con esquema común publicado y versionado con compatibilidad hacia atrás. El emisor que no cumple el esquema queda rechazado y registrado como falla del emisor.
- Llave de correlación del caso y del siniestro padre en cada evento. Es lo que hace posible la vista consolidada que el equipo ya pidió, y lo que no se puede agregar después sin reprocesar lo registrado.
- Ingesta idempotente y ventana para datos que llegan tarde. En autorizaciones los hits llegan desordenados y la evidencia de calidad aparece semanas después: si el modelo de datos cierra el caso al autorizar, esa evidencia no tiene dónde entrar.
- Una familia de indicadores de salud del ecosistema, que el equipo ya pidió como alertamiento: disponibilidad y latencia de cada fuente que un agente consulta, rezago del bus y cobertura de emisión. Sin ella, una fuente caída se lee como caída de acierto del agente, y el equipo termina ajustando un prompt para resolver un problema de red.

Qué cuesta

Instrumentar cada gestor mientras se construye, que es trabajo de días, más un consumidor común. Después es tocar código en producción, coordinar despliegues y reprocesar historia, multiplicado por seis. Buena parte de la recolección y el transporte no hay que construirla: son capacidades de plataforma que la organización ya opera o va a operar de todos modos.

Cómo se verifica

Todo evento valida contra el esquema publicado antes de entrar al bus, y la torre reporta qué proporción de los cambios de estado esperados está llegando efectivamente. Un gestor que deja de emitir es invisible en un tablero de negocio y evidente en ese indicador.

Qué acuerdos requiere

Acuerdo	Qué recomendamos	Dueño
Esquema del evento	Contrato del almacén y del bus, versionado, con los campos comunes de caso, línea de negocio, tipo de solicitud, gestor, agente con su versión y marca de tiempo.	Arquitectura con plataforma
Esquema de la traza	Sobre las convenciones semánticas de OpenTelemetry en su versión liberada 1.44.0 , que fijan cómo se nombran los atributos y son compatibles con cualquier plataforma de observabilidad. Las convenciones específicas de IA generativa están en desarrollo, así que conviene fijar esquema propio sobre la parte liberada.	Plataforma, con arquitectura y seguridad
Retención en dos horizontes	La traza técnica vive lo que dure el diagnóstico de un incidente; el registro que sustenta si una decisión estuvo bien vive hasta que llegue la glosa o la reclamación, y no queda sujeto a muestreo.	Arquitectura con seguridad

REFERENCIA DE MERCADO

El Reglamento europeo de inteligencia artificial exige, para los sistemas de alto riesgo, [conservación de registros que permitan la trazabilidad](#) y [archivos de registro generados automáticamente](#). No obliga en Colombia y lo citamos como referencia de mercado, no como cumplimiento exigible.

QUÉ SE PODRÁ AFIRMAR DESPUÉS Y HOY NO

La acertividad de cada agente con un número y su evidencia, en lugar de con la percepción del equipo que lo construyó.

Qué problema ataca

La vista ya tiene dibujados los tres lugares donde una persona corrige: el escalamiento a preradicado en el Gestor de Solicitud, la revisión humana de evaluación y la bandeja de autorizaciones-convenios. En la vista esas bandejas son destino, y ahí termina el trazo. Cada una de esas correcciones es, sin trabajo adicional, el dato que dice cuál era la respuesta correcta. Si se registra como texto libre, la evidencia de esos meses se pierde y después hay que pagar un etiquetado que hoy es gratuito.

Figura 2. El circuito que convierte una bandeja en verdad de referencia



En violeta claro, lo que ya está en la vista. En ámbar, lo que proponemos agregar: tres piezas, ninguna de ellas un sistema nuevo.

El circuito completo, del caso real al golden set y de vuelta al agente como compuerta de su próxima versión.

Cómo se ve

- Captura estructurada de la corrección en la pantalla de preradicado: qué campo estaba mal, cuál era el valor correcto y de dónde salía en el documento, en lugar de un comentario libre.
- Muestreo fijo de los casos aprobados desde el primer día. Es el único lugar donde aparece el error que nadie revisó, y en la vista actual el camino de aprobado no tiene retorno.
- Etiquetado retrospectivo del historial de solicitudes, para poblar el conjunto inicial antes de que exista un caso en vivo.
- Casos adversarios contruidos a propósito: escaneos ilegibles o rotados, órdenes con dos procedimientos, contradicciones entre historia y orden. Rara vez llegan en volumen por producción y son los que más definen la confiabilidad.
- Un golden set por gestor con dueño explícito, versionado, y balanceado entre casos que deben resolverse y casos que deben escalarse.

Qué cuesta

Un cambio acotado en la pantalla de preradicado y en las demás bandejas que ya se van a construir, un tiempo fijo de muestreo semanal y una persona responsable del conjunto por gestor. Es el complemento más barato de los siete y el que más habilita: sin él, C3 y C4 no tienen contra qué funcionar.

Cómo se verifica

Cada versión de agente declara contra qué versión del golden set se midió, y ese dato viaja en el registro de promoción. Si un agente no puede declararlo, no está medido.

PRÁCTICA DOCUMENTADA

La práctica que IBM documenta sobre [pruebas de agentes](#) insiste en tres propiedades del conjunto de casos: balanceado, incluyendo trayectorias que no deberían ocurrir; versionado y auditado, porque datos mal etiquetados producen métricas engañosas; y actualizado con ejemplos reales a medida que cambian los patrones de uso. Es práctica de fabricante, no norma.

C3 El auditor propone; una compuerta decide

Esfuerzo medio

Pasivo desde ya, activo con C2

Requiere C2

QUÉ SE PODRÁ AFIRMAR DESPUÉS Y HOY NO


Por qué el gestor se comporta hoy como se comporta, y cómo volver a como se comportaba ayer.

Qué problema ataca


La capa de auditoría está bien puesta, y en los dos gestores donde más importa. Es el mismo lugar donde la práctica de industria ubica los agentes de gobierno, y el propio equipo dejó anotada la cautela correcta cuando la describió como una capa que empieza informando. Lo que conviene abrir en dos es la flecha final: en la vista, el auditor aplica mejoras directamente sobre los agentes expertos. Proponer y promover no son el mismo acto, y esa flecha es, en nuestra experiencia, la que genera la pregunta más incómoda de una presentación a sponsor: si el sistema se ajusta solo, quién aprobó ese ajuste.

Figura 3. La flecha de mejora, abierta en dos

COMO ESTÁ EN LA VISTA



COMO PROPONEMOS DIBUJARLA



La capa de auditoría no se mueve de lugar; lo que se agrega son los dos pasos intermedios y el camino de vuelta.

Cómo se ve

- La recomendación produce una versión candidata, no un cambio. Solo la compuerta la convierte en la versión vigente.
- Criterio explícito de no regresión: si empeora en alguna métrica acordada no se promueve, aunque mejore en otras. Las excepciones se permiten, con registro firmado de quién asumió el riesgo.
- Cada caso corre varias veces, no una, y se reporta la consistencia entre corridas. El sistema es probabilístico y una sola corrida no distingue un agente confiable de uno afortunado.
- El artefacto que se versiona es la unidad completa: prompt, modelo, herramientas, política de memoria y umbrales. Actualizar la versión menor del modelo en uso también pasa por la compuerta.
- El LLM-as-a-judge previsto en esa capa se calibra contra una muestra revisada por personas expertas, y ese nivel de coincidencia se reporta junto a cualquier métrica que dependa de él. Trabaja con los evaluadores humanos, no los sustituye.
- Tres mecanismos de contención definidos desde el inicio: desactivar un agente de inmediato, volver a la versión anterior sin reconstruir nada, y cortar el acceso de un agente a una herramienta sin tumbar el gestor completo.
- El auditor se mide por resultado: no por cuántas recomendaciones produjo, sino por qué proporción de las aprobadas mejoró la métrica del agente auditado en la medición siguiente.

Qué cuesta

Trabajo de pipeline en cada gestor y cómputo por cada corrida de evaluación, que conviene medir como una métrica más. En modo pasivo, observar y notificar, casi nada: se puede activar en cuanto exista C1, y no hace falta esperar al resto.

Cómo se verifica

No existe promoción a producción sin ejecución de suite y resultado publicado: el despliegue falla si el resultado no viene adjunto. Y toda versión nueva vuelve a medirse en modo shadow o canary antes de recuperar el grado de autonomía que tenía la anterior.

REFERENCIA DE MERCADO

El mismo reglamento europeo pide que los sistemas de alto riesgo alcancen [un nivel adecuado de precisión, solidez y ciberseguridad, y lo mantengan de forma coherente durante todo su ciclo de vida](#). Una compuerta de no regresión es la forma operativa de sostener esa coherencia cuando el comportamiento depende de un prompt y de un modelo que cambian.

QUÉ SE PODRÁ AFIRMAR DESPUÉS Y HOY NO

Cuánta decisión automática está entregada, sobre qué tipos de caso y con qué respaldo, en una tabla que cabe en una lámina.

Qué problema ataca

Los tres puntos donde la vista decide —si la autorización está duplicada, si cumple la evaluación y si existe proveedor sugerido— están dibujados como rombos binarios. No dicen con qué confianza se decide, ni de dónde sale el umbral, ni cuánta autonomía tiene entregada el agente que decide. El propio equipo dejó ese pendiente escrito en sus requisitos técnicos: el nivel de autonomía de ejecución, recomendar frente a ejecutar, determina con qué sistemas hay que conectarse y qué capacidades de escritura hacen falta, y está pendiente de definir antes de dimensionar el desarrollo. Es también la pregunta que un sponsor hace primero y la que peor se responde improvisando.

Cómo se ve

Cuatro grados, que escribimos G1 a G4 y no niveles, porque en este proyecto la palabra nivel ya nombra otras dos escalas del negocio:

- **G1, en calibración.** Opera en modo shadow, sin decisiones reales; se compara su propuesta contra lo que de verdad ocurrió.
- **G2, supervisado.** Propone, y una persona revisa cada propuesta antes de ejecutarla.
- **G3, autónomo con umbral.** Decide solo cuando su confianza supera el umbral del tipo de caso, y escala por debajo. Es exactamente lo que hacen hoy los rombos de la vista y las bandejas que salen de ellos.
- **G4, autónomo pleno para ese tipo de caso.** Decide sin revisión previa, con auditoría posterior por muestreo.

El grado es por tipo de caso y no por agente: el mismo extractor puede estar en G4 para órdenes simples y en G2 para historias clínicas escaneadas. El ascenso pide volumen mínimo, acierto sostenido y ausencia de incidentes; el descenso se define con el mismo detalle, y una versión nueva corre un período en modo shadow o canary antes de recuperar el grado de la anterior.

Las tres escalas, para que no se confundan en la misma conversación

Escala	Qué mide	Valores
Nivel de escalamiento	A qué perfil humano se escala una solicitud.	1 automático · 2 administrativo · 3 enfermeras e instrumentadoras · 4 médicos y especialistas
Nivel de servicio	Complejidad y riesgo del servicio solicitado, que decide si puede ir por vía automática.	1 a 4, donde 3 y 4 son alto costo o riesgo
Grado de autonomía	Cuánta decisión automática tiene entregada un agente, para un tipo de caso.	G1 calibración · G2 supervisado · G3 con umbral · G4 pleno

Hay además una cuarta escala que conviene no mezclar con estas: los niveles de madurez agéntica que el equipo definió para el Gestor de Coordinación, de determinístico a asistente explicativo y a agente autónomo. Miden qué tipo de componente es y cómo se espera que evolucione; el grado mide cuánta decisión tiene entregada hoy. Conviven sin estorbarse.

Los techos que el negocio ya fijó

Tres decisiones ya tomadas que ningún ascenso puede superar, por buena que sea la métrica. Conviene que la vista las muestre como techo y no como oportunidad de mejora, porque son lo que permite dar autonomía real donde sí se puede.

Decisión ya tomada	Techo que impone
Ningún agente rechaza una solicitud. Ante la posibilidad de un rechazo, escala.	No es un techo que suba con mejor métrica: la negación no es una capacidad de los agentes. Para negar no existe G3 ni G4.
La negación debe ser determinística y trazable, nunca probabilística.	Se sustenta en reglas versionadas, que es justo lo que la caché de reglas duras de la vista ya permite. El modelo solo aporta el concepto que acelera la revisión.
La autorización automática aplica solo a servicios de nivel 1; los de nivel 3 y 4 van siempre a evaluación manual.	En alto costo y alto riesgo el techo es G2, sin importar el acierto medido.

Qué cuesta

Acordar una vez las categorías y los cuatro grados. Los números concretos por agente se fijan cuando ese agente empieza su construcción, con contexto real de dominio y de volumen. La implementación es baja porque la API de parametrización ya está prevista

en el diseño de la torre; lo que se agrega es el contrato y el registro.

Cómo se verifica

La API rechaza cualquier cambio de grado que no referencie un registro de decisión con su evidencia, y ningún agente sube de grado por decisión de quien lo construyó. La señal de que la escala funciona no son los ascensos, que se dan solos, sino que al menos un agente haya bajado de grado por evidencia y no por incidente.

REFERENCIA DE MERCADO

El reglamento europeo establece que las medidas de supervisión humana serán proporcionales a los riesgos, al nivel de autonomía y al contexto de uso. Es el sustento directo de una escala por tipo de caso en lugar de un interruptor por agente.

C5 Escalar con motivo, en lugar de cerrar el camino

Esfuerzo bajo

Al nombrar los estados

QUÉ SE PODRÁ AFIRMAR DESPUÉS Y HOY NO


Que la detección de duplicados acierta, con dos números separados: cuánto de lo que señaló era duplicado, y cuánto de lo que dejó pasar no lo era.

Qué problema ataca


Dos caminos automáticos de la vista terminan en un estado que dice rechazo: la capa de duplicidad en *rechazada por duplicidad*, y la de evaluación en *rechazada pendiente revisión humana*. En los dos casos lo que realmente ocurre es un escalamiento. En el primero, porque decidir si dos solicitudes son equivalentes es un juicio, no una comparación de campos; y un caso bloqueado no vuelve, así que la capacidad se vuelve imposible de medir. En el segundo, porque el estado nombra como decidido un caso que todavía nadie decidió. Es además el punto donde la vista se separa de una decisión que el propio equipo ya tomó: ningún agente niega.

Figura 4. El mismo camino, nombrado por lo que es

COMO ESTÁ EN LA VISTA



COMO PROPONEMOS DIBUJARLO



El trabajo del agente no es bloquear: es detectar bien y explicar por qué, y eso sí se puede medir

El flujo no cambia de forma; cambia el nombre del estado y el destino del caso, y con eso la capacidad se vuelve medible.

Cómo se ve

- **Escalada por posible duplicado**, con el motivo explícito y la evidencia de con cuál solicitud se parece. La persona decide si coincide, y esa decisión es la que mide al agente.
- **Escalada a evaluación humana** en lugar de rechazada pendiente de revisión. El estado nombra lo que el caso es, no lo que podría llegar a ser. Cuando el agente cree que el caso es candidato a negación, lo señala como tal en el escalamiento; negar sigue siendo de la persona.
- La detección se mide con dos números separados: acierto y falsos positivos. Un falso positivo que bloquea es un asegurado sin autorización; un falso positivo que escala es media hora de una persona.
- Aviso al asegurado cuando alguien radica en su nombre, que es lo que evita el duplicado en origen en lugar de detectarlo al final.

Qué cuesta

Nombres de estado, una bandeja más con su dueño y el campo de motivo en el evento de escalamiento. No cambia el flujo dibujado ni agrega componentes.

Cómo se verifica

Ningún camino automático de la vista termina en un estado terminal negativo sin que haya pasado una persona. Es una verificación que se puede hacer sobre el diagrama antes de escribir una línea de código.

POR QUÉ ESTO FORTALECE LA VISTA EN LUGAR DE COMPLICARLA

Un rombo que rechaza obliga a defender, frente al sponsor, la calidad del algoritmo de comparación. Un rombo que escala con motivo traslada la conversación a un terreno mucho más cómodo: cuánto trabajo humano ahorra la detección y con qué tasa de falsos positivos. La segunda conversación se gana con datos; la primera, no.

QUÉ SE PODRÁ AFIRMAR DESPUÉS Y HOY NO

Qué le está permitido a cada agente, qué herramientas puede invocar, cuánto cuesta y quién puede ver qué parte de la historia clínica.

Qué problema ataca

La vista muestra quince componentes agénticos y modelos expertos repartidos en cuatro gestores, y no muestra dónde se declaran sus prompts, sus modelos, sus permisos ni su inventario de herramientas. El AI Control Plane con su LLM Gateway, su Prompt Management y su runtime agéntico ya existe en el diseño del equipo; lo que proponemos es que aparezca también aquí, porque es la respuesta a dos preguntas que en un comité llegan juntas: quién controla la inteligencia artificial, y dónde está el dato del paciente. La interoperabilidad, que hoy figura como nota al margen sin conexión, pertenece a esa misma respuesta.

Cómo se ve

- El AI Control Plane como plano transversal bajo los cuatro gestores: registro de agentes y herramientas, permisos, versión de prompt y de modelo, y atribución de costo por línea de negocio, gestor, agente y caso.
- La distinción que hace el trabajo, dibujada: el plano de control decide *qué le está permitido* a un agente; la torre observa *qué hizo* y con qué resultado. Mezclarlos hace que un cambio de tablero pueda alterar el comportamiento de un agente.
- La interoperabilidad conectada según el principio que el equipo ya fijó: el dato se pide al core, y la conexión directa solo se justifica cuando el core no lo tiene ni lo va a tener. Hoy la interoperabilidad clínica cubre cerca del treinta por ciento de prestadores y solo consulta externa, así que conviene que la vista muestre su alcance y no solo su existencia.
- Retención en dos horizontes, decidida antes de emitir el primer evento. La traza técnica vive lo que dure el diagnóstico de un incidente; el registro que sustenta si una decisión estuvo bien vive hasta que llegue la glosa o la reclamación, y no puede quedar sujeto a muestreo.
- Filtrado por perfil antes de construir la vista, no después, y los tableros de prestador y de asegurado tratados como superficies externas con su propio control de acceso, aunque vivan en el mismo componente.

Qué cuesta

En la vista, un plano y tres flechas. En construcción es sobre todo declarar lo que de todos modos se va a usar, y decidir temprano la retención, que es lo único de esta lista que después obliga a reprocesar.

Cómo se verifica

Toda invocación de herramienta queda en la traza con su agente y su versión, y ningún tablero externo recibe campos que su perfil no puede ver. La segunda se verifica mirando la respuesta de la API, no la interfaz: recortar columnas en pantalla no es filtrar.

MARCO APLICABLE EN COLOMBIA

Lo que aplica de forma directa es el régimen de protección de datos personales, la [Ley 1581 de 2012](#), que clasifica los datos de salud como sensibles, y la normativa de historia clínica, la [Resolución 1995 de 1999](#) del Ministerio de Salud. Como referencia de mercado, el reglamento europeo clasifica de alto riesgo los sistemas usados para [evaluar la elegibilidad de personas a servicios esenciales de salud, y para evaluación de riesgos y tarificación en seguros de vida y salud](#). Una preautorización vive en ese vecindario, y eso explica el estándar de cuidado, no una obligación.

C7 El reloj tardío: de la autorización a la glosa

Esfuerzo medio

Cuando exista el lago de datos

Requiere C1 y C2

QUÉ SE PODRÁ AFIRMAR DESPUÉS Y HOY NO

Que las autorizaciones que el sistema emitió solo estaban bien emitidas, medido con la glosa y la reclamación que llegaron después y no con la confianza que declaró el modelo.

Qué problema ataca

La vista termina donde termina la operación: aprobada, autorizado, coordinado. Los gestores de prestación y de finalización están presentes como bloque, sin contenido, y son precisamente los que cierran el circuito. La cuenta médica, las glosas, las negaciones revertidas y las tutelas no aparecen como fuentes de nada. Sin ellas, la única evidencia disponible es la del momento de decidir, que es justo la que no distingue una autorización bien emitida de una emitida sin sustento. Y es la pregunta con más consecuencia de la presentación: el sponsor no está comprando velocidad, está comprando que la velocidad no salga caro.

Figura 5. Los tres momentos en que se conoce la calidad de una decisión



Los tres relojes miden la misma decisión en tres momentos distintos. La vista cubre bien los dos primeros; el tercero es el que contiene la verdad en seguros.

Cómo se ve

- Cuenta médica, glosas con su causal, negaciones revertidas, reprocesos y tutelas tratados como entrada de primera clase desde el diseño inicial, no como analítica financiera que llega al final.
- Confirmación de la atención por tres caminos con alcance distinto, cada uno con su nivel de confianza publicado junto al indicador: la agenda dentro de la red, que es la fuente más fuerte donde existe; la interoperabilidad clínica donde la haya; y el front de canales cuando el asegurado confirma. Fuera de la red la confirmación depende de los dos últimos.
- Los patrones de integridad nombrados uno por uno, porque cada uno se trata distinto: duplicidad, fragmentación de un servicio para quedar bajo umbrales de revisión, desvío entre lo autorizado y lo facturado, prestador atípico frente a su grupo comparable, y recurrencia sin atención.
- Un contenido mínimo para el Gestor de Finalización en la vista: es el que enlaza el desenlace con la cuenta médica, y sin ese enlace el reloj tardío no tiene por dónde entrar.

LA TORRE SEÑALA, NO ACUSA

Ninguna consecuencia hacia un prestador o un asegurado debería dispararse de forma automática desde esta capa. Una anomalía es una hipótesis con evidencia, y su destino es una cola de investigación humana con su propio registro. Automatizar la sanción convierte un falso positivo estadístico en un daño real y difícil de deshacer, y expone a la organización más de lo que la protege.

Qué cuesta

Depende del lago de datos de autorizaciones y de acordar la llave de correlación con la cuenta médica. Nosotros aportamos el orden de dependencia; el plazo lo declara su dueño. Lo que sí se puede hacer desde ahora, sin esperar a nadie, es que el modelo de datos admita evidencia rezagada sobre un caso ya cerrado operativamente: eso es de C1 y es lo único que después obliga a rehacer el modelo.

Cómo se verifica

Existe al menos un caso donde una glosa quedó correlacionada con la decisión que la originó, y ese caso entró al golden set del agente responsable sin que nadie lo moviera a mano.


REFERENCIA DE MERCADO

El reglamento europeo exige para los sistemas de alto riesgo un plan formal de [vigilancia poscomercialización](#), que es exactamente esto: recoger y analizar de forma activa la experiencia de uso después del despliegue. Referencia de mercado, no obligación local.

La vista complementaria

Los siete complementos, ubicados sobre la misma vista. Es la versión que proponemos, no una copia del diseño actual: se dibuja en ámbar lo que se agrega y en naranja los nombres y las formas que conviene replantear, para que se vea de un golpe qué cambia y por qué. La estructura de gestores no se mueve, ninguna pieza cambia de lugar, y todo lo nuevo entra como banda transversal o como retorno.

Figura 6. Los siete complementos sobre la vista de resumen



En ámbar, los siete complementos. En violeta y gris, lo que la vista ya tiene. La estructura de gestores no se mueve.

Todo lo que se agrega entra como banda transversal o como retorno hacia el golden set. Ningún gestor cambia de responsabilidad.

CUATRO DETALLES DE FORMA, PENSANDO EN LA LÁMINA

Conviene que los tres modelos expertos de coordinación lleguen con nombre, porque un recuadro sin nombre es la primera pregunta que hace un sponsor y desvía la conversación. Conviene también un solo recurso visual que distinga lo que ya opera de lo que está en construcción, que hoy se lee por el trazo pero no está en la convención. Y conviene que la convención de elementos aparezca en la misma lámina: la diferencia entre componente agéntico, modelo experto y regla dura es justamente la que sostiene la respuesta a por qué una negación no la decide un modelo. Por último, el rombo conviene reservarlo para las decisiones. Hoy la vista tiene cinco: tres son decisiones —si la solicitud ya existe, si cumple la evaluación y si hay proveedor sugerido— y dos, *Evaluar proveedor* y *Sugerir proveedor*, son pasos. En la vista complementaria dibujamos esos dos como pasos, para que los rombos de la lámina sean exactamente los puntos donde el sistema decide, que son los que un sponsor va a contar.

Secuencia recomendada y riesgos

Nuestra recomendación de orden, con el criterio detrás de cada paso:

- 1 C1, eventos y torre con contenido.** Primero, porque todo lo demás lee de ahí y porque cada semana sin instrumentar es evidencia que no se recupera. No depende del core ni del lago de datos.
- 2 C2, la corrección humana capturada.** En paralelo con C1 si hay capacidad, e inmediatamente después si no. Es el más barato y el que más habilita.
- 3 C5 y C6, en la vista, esta semana.** Los dos son sobre todo nombres de estado y un plano que ya existe en el diseño. Son los que más cambian la lámina con menos trabajo, y los que evitan las dos preguntas más incómodas de la presentación.
- 4 C4, grados de autonomía.** Antes de que el primer agente decida sin revisión previa, no después. El acuerdo de categorías se puede tomar ya; los números por agente se fijan cuando ese agente se construye.
- 5 C3, auditor con compuerta.** En modo pasivo desde que exista C1; en modo activo cuando C2 tenga volumen suficiente para que la compuerta signifique algo.

6 **C7, reloj tardío.** Cuando exista el lago de datos de autorizaciones. Lo único que no conviene diferir es la ventana para datos rezagados, que es de C1.

Los riesgos de este enfoque

Nos parece honesto nombrar lo que puede salir mal con lo que estamos proponiendo, no solo lo que habilita.

Que la vista se vuelva ilegible

Siete adiciones sobre una vista ya densa pueden convertirla en un mapa que nadie lee. Mitigación: en la lámina de sponsor los complementos entran como bandas y retornos, sin detalle interno; el detalle vive en las vistas por gestor que el equipo ya tiene.

Que la métrica se vuelva el objetivo

Cuando un número decide ascensos, el sistema tiende a optimizarlo a costa del resultado que representaba. Mitigación: una métrica de negocio siempre al lado de la técnica, y el error caro leído junto a la resolución sin intervención.

Que instrumentar se sienta burocrático

Si capturar la corrección hace más lento el trabajo en la bandeja, se llena mal y el golden set queda contaminado. Mitigación: diseñarla con quienes la usan y medir cuánto tiempo agrega.

Que el golden set envejezca

Un conjunto que ya no representa el proceso aprueba lo que debería frenar. Mitigación: dueño explícito, refresco periódico y revisión ante señales de deriva.

Que la torre termine decidiendo

Bajo presión operativa es tentador dejar que la torre resuelva. Mitigación: la torre puede cambiar cómo se mueve una solicitud, no qué se decidió sobre ella; y si una capacidad decide sobre el negocio, entra a la escala de grados como cualquier agente.

Que evaluar cueste más que ejecutar

Suites completas con repeticiones tienen costo real de cómputo. Mitigación: suite corta en cada cambio, completa en la promoción, y medir el costo de evaluar como una métrica más.

CÓMO PROPONEMOS REVISAR ESTO

Un chequeo rápido a las dos semanas de iniciados C1 y C2, para detectar temprano si algo no encaja, y una revisión más completa al mes. Si al mes el catálogo de métricas no tiene fichas publicadas o el golden set no tiene dueño, eso no es un retraso de cronograma: es la señal de que el enfoque no está siendo adoptado, y conviene hablarlo de frente en lugar de esperar.

Cobertura, pieza por pieza

Qué resuelve cada elemento de la vista, y qué complemento lo extiende.

Este anexo existe para que se pueda verificar que leímos la vista completa, sin que esa verificación invada el cuerpo del documento. Las diecinueve filas recorren la vista completa, pieza por pieza: la columna del medio dice qué resuelve hoy cada una, y la última, qué de esta propuesta la extiende y por dónde.

Pieza de la vista	Qué resuelve hoy	Qué la extiende
Banda de torre de control, con front y back	Declara la torre como pieza del sistema y le reserva su lugar en la vista.	C1 le da destino y contenido; C4 le da el semáforo de grados
Canales y los tres perfiles de persona	El catálogo completo de entrada, con portal, superapps, WhatsApp, AVA, SVP, Nexo y chat conversacional.	C1, marca de origen en el evento, para que los casos que entran por caminos que se saltan gestores no contaminen la métrica de quien no participó
API orquestadora por tipo de solicitud	El nivel alto de la jerarquía: interpreta la solicitud y decide qué se necesita. Está en los tres gestores, con el mismo nombre.	C1, hito de solicitud recibida; C4, el grado se declara por tipo de caso, que es lo que esta API ya distingue
Receptor y enrutador de documentos	El nivel medio: valida que los archivos correspondan e identifica dónde está cada documento.	C2, acierto de clasificación y matriz de confusión contra el tipo confirmado por una persona
Los cuatro extractores en paralelo	El nivel bajo, un experto por documento, con el reparto que evita que la latencia sea la suma.	C2, acierto por campo y proporción de campos con respaldo verificable en la fuente
Agente request builder	Consolida el análisis de los expertos y arma la solicitud según el tipo.	C1, validez de esquema del contrato hacia Evaluación, verificada automáticamente
LLM-as-a-judge	Está previsto en la capa de entrada y salida, como la vía para evaluar lo que no se puede verificar con reglas. Es la única forma de hacerlo a escala.	C3, calibrarlo contra una muestra revisada por personas expertas y reportar ese nivel de coincidencia junto a la métrica que dependa de él
Capa de auditoría, en Solicitud y en Evaluación	El agente auditor existe, está en los dos gestores donde más importa y en el plano correcto.	C3, abrir la flecha de aplicar mejoras en versión candidata, compuerta y promoción registrada
Capa de duplicidad	Detecta solicitudes equivalentes antes de evaluar, que es donde el equipo ya identificó el riesgo.	C5, escalar con motivo y evidencia en lugar de cerrar el camino, que es lo que además la vuelve medible
Caché de reglas duras y modelo experto	Separa lo determinístico de lo que admite juicio, dentro de la misma capa de evaluación.	C4, es lo que sostiene el techo de negación determinística; C6, versión y vigencia de la regla registradas en cada decisión
Información del cliente y pertinencia médica	El componente analítico que aporta el criterio clínico a la evaluación.	C2, concordancia con la decisión humana, medida por separado para autorizar y para escalar
Rombo de cumplimiento de la evaluación	El punto donde el caso se aprueba o pasa a una persona. La bifurcación está bien puesta.	C4, con qué umbral y con qué grado se decide; C5, cómo se llama el estado del caso que pasa a una persona
Modelos expertos de coordinación	El coordinador de autorización y los que vienen detrás, con la madurez agéntica que el equipo ya definió para este gestor.	C4, el grado convive con la madurez: una dice qué tipo de componente es, el otro cuánta decisión tiene entregada hoy
Decisión de proveedor y sus dos pasos	El punto donde se resuelve si hay proveedor sugerido, y las dos acciones que salen de ahí: evaluarlo o sugerir uno.	Notación - el rombo se reserva para la decisión, y evaluar y sugerir se dibujan como los pasos que son
Bandejas de coordinación	Dos estados nombrados, con su condición de entrada y su dueño humano. Nombrar la bandeja ya definió el estado.	C2, el ajuste que hace la persona sobre el prestador sugerido es una etiqueta, y hoy el trazo termina en la bandeja
Gestor de prestación y Gestor de finalización	Están presentes como bloque, que es la forma correcta de declarar alcance sin comprometer detalle.	C7, la confirmación de la atención con su nivel de confianza, y el enlace del desenlace con la cuenta médica
Interoperabilidad, marcada como relevante	Reconoce la pieza y su importancia dentro del ecosistema.	C6, conectarla según el principio de responsabilidad única, vía el core, y declarar su alcance real y no solo su existencia
Generador de evento, en la convención de elementos	El emisor está previsto como tipo de componente de primera clase.	C1, el destino de ese evento: bus compartido, esquema versionado y llave de correlación

Pieza de la vista	Qué resuelve hoy	Qué la extiende
core, Surahis, P8 y Siniestro Integral	Los sistemas de registro y de documentos, con su lugar y su relación con los gestores.	C1, la llave del siniestro padre; C6, el core como intermediario antes de una conexión directa

LO QUE MUESTRA LA TABLA

Ninguno de los siete complementos pide mover una pieza de lugar ni redistribuir responsabilidades entre gestores. De los siete, seis extienden algo que ya está dibujado; uno solo, el bus de eventos, agrega una pieza, y es la que la convención de elementos de la vista ya anticipaba al declarar el generador de evento.

Lo que queda explícitamente fuera

El detalle interno de los gestores que la vista de resumen no desarrolla, que vive en las otras vistas del mismo archivo y no pertenece a una lámina de sponsor. El dimensionamiento del esfuerzo, que depende de decisiones que todavía no están tomadas. Y el catálogo de indicadores de operación del equipo, que se referencia y no se copia: los indicadores de actividad se enchufan en sus ejes de calidad, riesgos operativos, impacto financiero y automatización, sin reemplazar ninguno.

De dónde viene cada afirmación de este documento.

Diseños del equipo, fuente primaria

- Arquitectura de gestores, en su versión del 2 de septiembre de 2026, vista *Resumen*, que es el objeto de estas notas. Las demás vistas del mismo archivo se leyeron como contexto y no se auditan aquí.
- Seguimiento de requerimientos de Gestores 2026 y ficha integral de la iniciativa, de donde provienen los requisitos técnicos y funcionales citados, los pendientes abiertos y el registro de riesgos.
- Cronograma de releases de alto nivel, de donde proviene el orden de dependencia del lago de datos de autorizaciones.

Estándares y normas, citados como referencia de mercado

Ninguna de estas normas obliga a SURA en Colombia. Se citan porque son la referencia que un auditor, un reasegurador o un socio internacional van a reconocer, y cada afirmación que se apoya en una lleva su enlace en el mismo bloque donde aparece.

- Reglamento (UE) 2024/1689**, texto publicado en el Diario Oficial: [artículo 12, conservación de registros](#) · [artículo 14, supervisión humana](#) · [artículo 15, precisión y solidez](#) · [artículo 19, archivos de registro automáticos](#) · [artículo 72, vigilancia poscomercialización](#) · [anexo III, puntos 5\(a\) y 5\(c\)](#).
- OpenTelemetry**, [convenciones semánticas en su versión liberada 1.44.0](#). Se citan como convención de esquema, no como herramienta. Las convenciones específicas de inteligencia artificial generativa están en desarrollo y no se citan aquí como estándar.
- ISO/IEC 42001:2023**, [sistema de gestión de inteligencia artificial](#), y **ISO/IEC 23894:2023**, [guía de gestión de riesgos de IA](#).
- NIST**, [AI Risk Management Framework 1.0](#) y su Playbook, de uso voluntario.
- NAIC**, [boletín modelo sobre el uso de sistemas de IA por aseguradoras](#), adoptado en diciembre de 2023: exige un programa escrito, proporcional al riesgo, que el regulador puede solicitar en un examen.
- EIOPA**, [opinión sobre gobernanza y gestión de riesgos de inteligencia artificial](#), agosto de 2025, con enfoque basado en riesgo y proporcionalidad.

Marco aplicable en Colombia

- Ley 1581 de 2012**, régimen general de protección de datos personales, que clasifica los datos de salud como sensibles.
- Resolución 1995 de 1999** del Ministerio de Salud, normas para el manejo de la historia clínica.
- La Superintendencia Financiera ha comunicado su enfoque sobre [inteligencia artificial aplicada al sector financiero](#), con intervención humana en el bucle. No encontramos norma local específica sobre sistemas agénticos.

Práctica documentada de fabricante

Se cita desde el sitio oficial y se presenta como práctica documentada, nunca como norma.

- IBM Think, [pruebas de agentes](#): componente, trayectoria y extremo a extremo, y las propiedades del conjunto de casos.
- IBM Think, [plano de control de agentes](#): registro, permisos, ciclo de vida y la distinción entre medir y permitir.
- IBM Think, [gestión del ciclo de vida de agentes](#), de donde viene ubicar el grado de autonomía en la fase de planificación de cada agente.
- IBM Think, [gobierno de agentes](#): agentes de gobierno y mecanismos de contención.

Este documento recoge la lectura profesional de Tech and Solve sobre la vista de resumen y la evidencia disponible en esta etapa. Cada complemento es un punto de partida para la discusión: queda al criterio del equipo de SURA adoptarlo, ajustarlo o descartarlo.