

Notas de arquitectura

Seis propuestas para medir la acertividad de los agentes y para entregarles autonomía con evidencia, sobre el diseño que el equipo ya tiene en marcha.

SURA Colombia · Transformación prestación y reclamaciones, MVP autorizaciones de salud

Elaborado por Tech and Solve para SURA · Agosto de 2026

Elaborado sobre los diseños vigentes del equipo, *Arquitectura-Gestores* y *Arquitectura-Gestores General Transversal*.

Objetivo

QUÉ QUEREMOS QUE QUEDE ACORDADO

Cómo se mide la acertividad de un agente y cómo se le autoriza autonomía, de forma que el MVP pueda pasar de piloto a operación sin frenar la construcción.

Revisamos los diseños que el equipo tiene hoy en marcha y de esa lectura salen seis propuestas concretas. Todas se apoyan en componentes que ya existen en el diagrama, y todas responden a algo que ustedes ya dejaron anotado como pendiente. Son sugerencias: cada una se puede tomar, ajustar o descartar sin que se caigan las demás.

Cada propuesta se lee en una página y dice lo mismo en el mismo orden: qué habilita, qué problema ataca, cómo se ve, qué cuesta, cómo se verifica y qué acuerdos requiere. Al final hay una secuencia recomendada de adopción. El marco conceptual y el sustento de la industria están en los anexos, para que el cuerpo del documento sea la propuesta y no la teoría.

Qué no proponemos


- No proponemos cambiar la arquitectura de gestores ni redistribuir sus responsabilidades.
- No proponemos introducir una plataforma nueva: todo se conecta a la torre de control, al plano de control de IA y al almacén de eventos que ya están diseñados.
- No proponemos frenar la construcción para medir primero. Las seis propuestas están pensadas para avanzar en paralelo al desarrollo.
- No proponemos un comité de aprobación. Cinco de las seis propuestas viven dentro del pipeline de cada equipo y se ejecutan solas.

Punto de partida

El diseño vigente describe un motor de gestión de solicitudes reutilizable, hoy activo en Salud, con seis gestores y entrada separada por línea de negocio. Existe un plano de control de IA con puerta de acceso a modelos, gestión de prompts, ejecución agéntica e inventario de herramientas. Y existe una torre de control que declara trazabilidad de punta a punta, alertas por tiempos y criticidad, analítica para mejora continua y control de niveles de autonomía, con una interfaz y una API para parametrizarlos.

Sobre esa base, las seis propuestas no agregan piezas: definen **qué se escribe en las piezas que ya están**. Esa es la razón por la que el esfuerzo es menor de lo que suele ser en proyectos donde la medición se agrega después.

Figura 1. El sistema tal como está diseñado hoy



Los eventos suben
de los gestores a la torre de control y al lago de datos

Las políticas bajan
prompts, modelos y permisos desde el plano de control de IA

Reconstrucción de los diseños vigentes del equipo. En violeta oscuro, lo que está activo hoy en la línea de Salud.

Las seis propuestas

Propuesta	Qué habilita	Esfuerzo	
P1	Una traza y un evento comunes para los seis gestores	Reconstruir por qué un agente decidió, y atribuir tiempo y costo por caso.	Medio
P2	Producir la verdad de referencia desde preradicado	Medir acertividad con datos reales, sin montar un proyecto de datos aparte.	Bajo
P3	Una compuerta antes de producción	Cambiar prompts y modelos rápido sin romper lo que ya funcionaba.	Medio
P4	Escala de madurez conectada a la API de autonomía	Entregar autonomía con evidencia, y retirarla sin discusión política.	Bajo
P5	El agente auditor como capa pasiva con compuerta	Mejora continua que se puede auditar, y no deriva silenciosa.	Medio
P6	Umbral derivado del costo del error	Decidir cuánto riesgo se acepta con un número acordado, no con intuición.	Bajo

NUESTRA RECOMENDACIÓN DE ORDEN

P1 y P2 primero, y en ese orden, porque son las únicas cuya oportunidad se pierde: la evidencia que no se captura hoy no se recupera después. Con esas dos en pie, P3 es casi inmediata. P4, P5 y P6 dependen de tener medición, así que llegan después, aunque P6 se puede acordar con el negocio en paralelo desde el primer día.

P1 Una traza y un evento comunes para los seis gestores

Esfuerzo medio

Antes de que un segundo gestor empiece a emitir

QUÉ HABILITA

Poder reconstruir por qué un agente decidió lo que decidió, atribuir tiempo y costo caso por caso, y darle a la torre de control con qué llenar los tableros que ya tiene diseñados.

Qué problema ataca

Hoy cada gestor podría definir su propio formato de traza y de evento, y sin embargo la torre de control y el lago de datos consumen de todos. Cuando eso se descubre tarde, la corrección obliga a tocar los seis gestores y se pierde la comparabilidad de lo ya registrado. El diseño ya tiene la inquietud escrita.

ANOTADO EN EL DISEÑO DEL GESTOR DE SOLICITUD

"En caso de que el gestor falle en la identificación, debe dejar registro del porqué falló."

Nuestra propuesta extiende esa idea a los casos exitosos y a todos los gestores: no basta registrar el fallo, hay que registrar la decisión completa, incluso cuando salió bien.

Figura 2. Vista dinámica: una solicitud recorriendo el Gestor de Solicitud



8. Cada paso emite traza y evento, de forma asíncrona

entrada, salida, herramienta usada, confianza, latencia, costo y versión del agente, hacia el almacén de eventos y la torre de control

El paso 7 es la única compuerta automática del recorrido: lo que no la pasa no avanza, y eso es lo que hace medible al gestor.

Los pasos 2 y 5 son internos del gestor; el paso 8 es lo que permite reconstruir después qué ocurrió y por qué.

Cómo se ve

- Campos mínimos obligatorios por paso: entrada, salida, herramienta invocada con sus parámetros, confianza declarada, latencia, costo y versión del artefacto del agente.
- Un estándar abierto de telemetría en lugar de un formato propio, para no reinventar el vocabulario ni quedar atados a una herramienta.
- Correlación obligatoria con el caso y con el siniestro padre, y marca del origen de la solicitud, para que los casos creados por caminos que se saltan gestores no contaminen las métricas de quien no participó.
- Retención y tratamiento de datos sensibles definidos desde el inicio, por tratarse de información clínica.

Qué cuesta

Instrumentar cada agente una vez, con ganchos que capturan la traza en los puntos clave del flujo, y acordar el esquema antes de que más gestores empiecen a emitir. El costo real no es técnico, es de disciplina: nadie debería poder emitir por fuera del esquema.

Cómo se verifica

Todo evento valida contra el esquema publicado antes de entrar al bróker, y un evento inválido se rechaza y queda registrado como falla del emisor. Un muestreo automático verifica presencia de campos obligatorios y falla el despliegue si baja del umbral acordado.

Acuerdos que requiere

Acuerdo	Qué recomendamos	Dueño
D4	Esquema de la traza y estándar abierto de telemetría, con campos mínimos obligatorios.	Plataforma, con arquitectura y seguridad
D1	Esquema del evento del almacén y bróker, versionado con compatibilidad hacia atrás.	Arquitectura con plataforma
D12	Atribución de costo y cuotas por línea, gestor, agente y caso en el plano de control de IA.	Plataforma del plano de control de IA

P2 Producir la verdad de referencia desde preradicado

Esfuerzo bajo

Desde el primer caso en vivo

QUÉ HABILITA

Medir la acertividad con casos reales y tener contra qué comparar cada versión nueva de un agente, sin montar un proyecto de etiquetado aparte.

Qué problema ataca

No se puede afirmar que un agente acierta sin saber cuál era la respuesta correcta. Y la fuente más barata de esa respuesta ya está en el flujo: cada solicitud que una persona revisa y corrige en preradicado produce, sin trabajo adicional, el dato que hace falta. Si esa corrección se captura como texto libre, la evidencia de esos meses se pierde y después hay que pagar un etiquetado que pudo ser gratuito.

ANOTADO EN EL DISEÑO, JUNTO A LA CAPA DE AUDITORÍA

"En los casos exitosos, ¿cómo registro una auditoría para validar que lo está haciendo bien?"

Figura 3. El circuito que convierte revisión humana en verdad de referencia



Cada corrección humana en preradicado es una etiqueta gratis: el trabajo ya se hizo, solo falta capturarlo con estructura.

Si esa captura no se diseña desde el inicio, el equipo va a pagar después por un ejercicio de etiquetado que pudo ser gratuito.

El circuito completo, del caso real al conjunto de oro y de vuelta al agente como compuerta de su próxima versión.

Cómo se ve

- **Captura estructurada de la corrección humana:** qué campo estaba mal, cuál era el valor correcto y de dónde salía en el documento, en lugar de un comentario libre.
- **Muestreo fijo de los casos aprobados** desde el primer día. Es el único lugar donde se puede detectar el error que nadie revisó.
- **Etiquetado retrospectivo del historial de solicitudes** para poblar el conjunto inicial antes de que exista un caso en vivo, aprovechando que el historial ya está conectado.
- **Casos adversarios contruidos a propósito:** escaneos ilegibles o rotados, órdenes con dos procedimientos, contradicciones entre historia y orden. Rara vez llegan en volumen por producción y son los que más definen la confiabilidad.
- Un **conjunto de oro con dueño explícito**, versionado, balanceado entre casos que deben resolverse y casos que deben escalarse, y refrescado periódicamente.

Qué cuesta

Un cambio acotado en la pantalla de preradicado, un tiempo fijo de muestreo semanal, y una persona responsable del conjunto por gestor. Es la propuesta más barata de las seis y la que más habilita: sin ella, P3, P5 y P6 no tienen con qué funcionar.

Cómo se verifica

Cada versión de agente declara contra qué versión del conjunto de oro se midió, y ese dato viaja en el registro de promoción. Si un agente no puede declararlo, no está medido.

Acuerdos que requiere

Acuerdo	Qué recomendamos	Dueño
D6	Círculo de verdad de referencia y dueño del conjunto de oro por gestor, con formato común.	Líder de cada gestor, formato dado por arquitectura
D5	Catálogo de métricas con su fórmula exacta, unidad de agregación y fuente de verdad.	Arquitectura con los líderes de gestor

SUSTENTO La práctica documentada insiste en tres propiedades del conjunto de casos: balanceado, incluyendo trayectorias que no deberían ocurrir; versionado y auditado, porque datos mal etiquetados producen métricas engañosas; y actualizado con ejemplos reales a medida que cambian los patrones de uso. El detalle está en el [anexo C](#).

P3 Una compuerta antes de producción

Esfuerzo medio

Antes de la primera versión que reemplace a otra

Requiere P2

QUÉ HABILITA

Cambiar prompts, modelos y herramientas con velocidad, sabiendo que una mejora no rompió en silencio tres cosas que ya funcionaban.

Qué problema ataca

El comportamiento de un agente depende de cuatro cosas que cambian con frecuencia: prompt, modelo, herramientas y política de memoria. Sin una compuerta, cada ajuste es un acto de fe, y el patrón conocido es mejorar el caso reportado y degradar otros sin que nadie lo note hasta que aparece un reclamo. Aplica también a lo que parece inofensivo: actualizar la versión menor del modelo que ya se está usando puede alterar el comportamiento de forma imprevisible.

ANOTADO EN EL DISEÑO, ENTRE LAS ACCIONES POR REVISAR

"Cómo capturar errores de los gestores para retroalimentación y aprendizaje de los gestores."

Figura 4. Los tres bucles, su reloj y su compuerta



Cómo se ve

- Tres bucles con relojes distintos y sin mezclarse: en **ejecución** se decide si el caso avanza o se escala, y no se aprende nada; en **cada cambio** se decide si una versión reemplaza a la anterior; en **gobierno** se decide cuánta autonomía tiene el agente.
- Suite corta y rápida en cada cambio, suite completa en la promoción.
- Cada caso corre varias veces, no una, y se reporta también la consistencia entre corridas, porque el sistema es probabilístico y una sola corrida no distingue un agente confiable de uno afortunado.
- Criterio explícito de no regresión: si empeora en alguna métrica acordada no se promueve, aunque mejore en otras. Las excepciones se permiten, con registro firmado de quién asumió el riesgo.
- El artefacto que se versiona es el conjunto completo de prompt, modelo, herramientas, política de memoria y umbrales, tratado como una unidad.

Qué cuesta

Trabajo de pipeline en cada gestor y costo de cómputo por cada corrida de evaluación, que conviene medir como una métrica más. Depende de P2: sin conjunto de oro, la compuerta no tiene contra qué comparar. La mitad de este costo ya está cubierta si el plano de control de IA versiona prompts, como está diseñado.

Cómo se verifica

No existe promoción a producción sin ejecución de suite y resultado publicado: el despliegue falla si el resultado no viene adjunto.

Acuerdos que requiere

Acuerdo	Qué recomendamos	Dueño
D7	Compuerta de regresión obligatoria antes de promover, con criterio de no regresión y excepciones registradas.	Equipo de cada gestor, obligación definida centralmente
D8	Qué se versiona como artefacto del agente: prompt, modelo, herramientas, memoria y umbrales, como una unidad.	Plataforma del plano de control de IA

P4 Una escala de madurez conectada a la API de autonomía

Esfuerzo bajo

Antes del primer agente que decida sin revisión


QUÉ HABILITA

Entregar autonomía a un agente con evidencia en la mano, retirarla sin que se convierta en una discusión política, y comparar dos agentes de dos equipos distintos con el mismo criterio.

Qué problema ataca

La torre de control ya declara que controla niveles de autonomía y expone una interfaz para parametrizarlos. Lo que falta es el vocabulario de esos niveles y la regla para moverse entre ellos. Sin eso, cada equipo define a su manera qué significa que su agente "ya está listo", y la palabra deja de servir para comparar o para decidir con criterio uniforme.

Figura 5. Los cuatro niveles del modelo de madurez de un agente



Cada ascenso exige, sin excepción:

volumen mínimo de casos procesados, tasa de acierto sostenida en un período definido, y ausencia de incidentes atribuibles a sus decisiones

El nivel no lo decide quien construyó el agente; lo aplica la API de parametrización de autonomía.

El nivel 3 es el mecanismo del paso 7 de la Figura 2: decidir solo, y escalar cuando la confianza no alcanza.

Cómo se ve

- **Nivel 1, en calibración:** opera en sombra, sin decisiones reales; se compara su propuesta contra lo que de verdad ocurrió.
- **Nivel 2, supervisado:** propone y un humano revisa cada propuesta antes de ejecutarla.
- **Nivel 3, autónomo con umbral:** decide solo cuando su confianza supera el umbral del tipo de caso, y escala por debajo. Es lo que en el diseño actual hacen la compuerta y las bandejas de preradicado y de evaluación por humano.
- **Nivel 4, autónomo pleno para ese tipo de caso:** decide sin revisión previa, con auditoría posterior por muestreo.
- El nivel es **por tipo de caso y no por agente**: el mismo extractor puede estar en nivel 4 para órdenes simples y en nivel 2 para historias clínicas escaneadas.
- Ascenso con criterio explícito, volumen mínimo, acierto sostenido y ausencia de incidentes, y **condición de descenso definida con el mismo detalle**. Y recalibración: una versión nueva corre un período en sombra o canario antes de recuperar el nivel que tenía la anterior.

Qué cuesta

Acordar una vez las categorías y los cuatro niveles, y definir los números concretos por agente cuando ese agente empieza su construcción, con contexto real de dominio y volumen. El costo de implementación es bajo porque la API ya está prevista; lo que se agrega es el contrato y el registro.

Cómo se verifica

La API rechaza cualquier cambio de nivel que no referencie un registro de decisión con su evidencia. Y ningún agente sube de nivel por decisión de quien lo construyó.

Acuerdos que requiere

Acuerdo	Qué recomendamos	Dueño
D9	Contrato de la API de parametrización: nivel vigente, umbral, modo de observación, criterio de ascenso y condición de descenso, cada uno con autoría y registro.	Arquitectura con el equipo de torre de control

SUSTENTO La práctica documentada ubica esta definición en la fase de planificación de cada agente: propósito, dueño de negocio, métricas de éxito, perfil de riesgo y nivel adecuado de autonomía, junto con los límites de autoridad y los puntos de aprobación humana.

P5 El agente auditor como capa pasiva, con compuerta para actuar

Esfuerzo medio

Pasivo desde ya, activo cuando existan P2 y P3

QUÉ HABILITA

Mejora continua que se puede auditar: cada cambio en el comportamiento de un agente queda explicado, medido y reversible, en lugar de acumularse como ajustes que nadie puede reconstruir.


Qué problema ataca

El diseño ya contempla un agente auditor que lee el historial, notifica recomendaciones de mejora y las aplica. La idea es correcta y coincide con lo que la industria llama agentes de gobierno. El riesgo está en el último paso: si el auditor escribe directamente sobre un agente en producción, el sistema se optimiza contra un criterio que nadie validó y se pierde la explicación de por qué el gestor se comporta hoy como se comporta. El propio equipo ya anotó la cautela correcta.

ANOTADO EN EL DISEÑO, EN LA CAPA DE AUDITORÍA

"Empieza como una capa pasiva para informar a torre de control sobre cómo se está comportando el gestor y a futuro poder modificar o reparar el agente."

Figura 6. El auditor propone; la compuerta decide



El auditor nunca escribe directamente sobre el agente en producción: propone una versión candidata.

Así el sistema conserva la trazabilidad de por qué el gestor se comporta hoy como se comporta.

Y el auditor tampoco se califica a sí mismo: se mide por si sus recomendaciones aprobadas mejoraron la métrica.

La diferencia entre un bucle de mejora y una deriva silenciosa es exactamente esta compuerta.

Cómo se ve

- **Propone, no aplica:** una recomendación se convierte en versión candidata y pasa por la compuerta de P3 antes de existir en producción.
- **Se mide por resultado:** su métrica no es cuántas recomendaciones produjo, sino qué proporción de las aprobadas mejoró la métrica del agente auditado en la medición siguiente.
- **No se juzga a sí mismo:** la evaluación la hace la suite con datos etiquetados, y la aprobación, la sesión de decisión.
- **Sus hallazgos alimentan el conjunto de oro:** cuando detecta un patrón de falla, lo valioso no es la recomendación de prompt, es el caso de prueba que impide que esa falla vuelva.
- **Vive en el plano de evaluación,** como servicio compartido, y no dentro del gestor que audita, para no heredar sus mismos supuestos y poder comparar entre gestores.
- **El front de ajuste de prompts y umbrales** que plantea el diseño sigue la misma regla: produce versión candidata, ofrece vista previa y simulación contra el conjunto de oro, y registra autor, motivo y resultado, con reversión inmediata.

Qué cuesta

En modo pasivo, casi nada: observa trazas y notifica a la torre de control, y se puede activar en cuanto exista P1. En modo activo depende de P2 y P3, y el front es desarrollo de producto. Nuestra recomendación es empezar pasivo ahora y no esperar a tener todo listo.

Cómo se verifica

Ningún cambio originado en el auditor o en el front llega a producción sin simulación ejecutada y aprobación registrada. Y toda versión nueva de un agente vuelve a medirse antes de recuperar el nivel de autonomía que tenía la anterior.

Acuerdos que requiere

Acuerdo	Qué recomendamos	Dueño
D11	Gobierno del front de ajuste de prompts y umbrales: versión candidata, simulación previa, registro y reversión, ubicado en la torre de control.	Arquitectura con torre de control y coordinación

P6 Un umbral derivado del costo del error, acordado con negocio

Esfuerzo bajo

Se puede acordar desde ya, en paralelo

QUÉ HABILITA

Fijar el umbral de confianza de cada agente con un criterio explícito y defendible, y que el dueño del riesgo aceptado sea el negocio y no una constante escondida en el código.

Qué problema ataca

El umbral es el parámetro más consecuente del sistema, porque decide cuánto trabajo humano se ahorra y cuánto riesgo se acepta. Y los dos errores posibles no cuestan lo mismo, así que elegirlo maximizando el acierto total esconde exactamente la diferencia que importa.

Situación	Consecuencia real	Quién paga
Escalamiento correcto	Una persona resuelve el caso, y su corrección alimenta el conjunto de oro.	Tiempo del equipo humano, con retorno
Escalamiento innecesario	Retraso y trabajo evitable; si es masivo, el gestor deja de aportar valor.	El equipo humano y el asegurado, en tiempo
Avance indebido	Contamina la evaluación clínica y de póliza, y es difícil de detectar después.	El asegurado, y SURA en riesgo y reputación

Cómo se ve

- Primero se acuerda el **límite tolerable del avance indebido** por tipo de caso, expresado como límite y no como meta. Solo después se elige el umbral que cumple ese límite.
- El umbral **no es único**: un procedimiento de alto costo puede exigir más que una solicitud rutinaria, aunque lo procese el mismo agente. Eso es una política en el plano de control, no una constante en el agente.
- Se verifica empíricamente que la **confianza declarada** por el modelo se relacione con el acierto real. Si la relación es débil, la compuerta principal pasan a ser las verificaciones deterministas: campos obligatorios presentes, valores con respaldo en el documento, coherencia entre historia y orden.

Qué cuesta

Una conversación con negocio y una revisión periódica. La medición del cumplimiento depende de P1 y P2, pero el acuerdo puede tomarse antes, y de hecho conviene, porque es el que orienta los umbrales de todos los agentes.

Cómo se verifica

Alerta automática cuando el error caro medido en la ventana definida supera el límite acordado, con descenso automático de nivel del agente responsable.

Acuerdos que requiere

Acuerdo	Qué recomendamos	Dueño
D10	Límite tolerable del error caro por tipo de caso, revisado con periodicidad fija y no solo después de un incidente.	Negocio, con arquitectura como facilitador

Dos acuerdos que conviene cerrar aparte

Estos dos no pertenecen a ninguna de las seis propuestas y no dependen de la medición, pero están marcados como pendientes en el propio diseño y son de los más costosos de revertir. Los dejamos aquí para que no se pierdan entre lo demás.

D2 Quién es dueño de la actualización de estados

Costoso de revertir

Pendiente en el diagrama

CONTEXTO	El diseño anota que falta definir quién actualiza los estados, la torre de control o el núcleo de registro. Con vistas materializadas de por medio, elegir mal se paga en inconsistencias difíciles de depurar.
RECOMENDACIÓN	El núcleo de registro como único dueño del estado autoritativo, por ser el sistema de registro; la torre de control como dueña de la vista materializada y de los meta-estados derivados. Ningún gestor escribe estado por fuera del camino definido. Nombrar las bandejas que hoy están sin nombre es parte de esta misma conversación, porque nombrar una bandeja es definir un estado y su dueño.
CÓMO SE VERIFICA	No existe ruta de escritura de estado fuera del camino definido, y una comparación periódica entre la vista y el núcleo alerta ante cualquier discrepancia.

D3 Custodia de las reglas: núcleo de registro o gestor

Costoso de revertir

Pregunta del equipo

CONTEXTO	El diseño pregunta si, siendo las reglas el eje de la evaluación, el custodio debería ser el núcleo o el gestor. Afecta a los cinco gestores restantes y a cualquier canal que decida sin pasar por ellos.
RECOMENDACIÓN	Separar dos cosas que hoy se llaman igual. Las reglas duras, deterministas y auditables, con versión y vigencia, en un custodio único fuera del agente. Las políticas de decisión del agente, prompt y umbrales, en el plano de control de IA. El criterio: si la regla debe aplicar también cuando el caso no pasa por un gestor, es del custodio único.
CÓMO SE VERIFICA	Toda decisión registra qué versión de reglas aplicó, y ninguna regla dura existe únicamente dentro de un prompt.

Secuencia recomendada y riesgos

Nuestra recomendación de orden, con el criterio detrás de cada paso:

- P1, traza y evento comunes.** Primero porque todo lo demás lee de ahí, y porque cada semana sin instrumentar es evidencia que no se recupera.
- P2, verdad de referencia desde preradicado.** En paralelo con P1 si hay capacidad, e inmediatamente después si no. Es la propuesta más barata y la que más habilita.
- P6, límite del error caro.** Se acuerda con negocio en paralelo desde el primer día, porque no depende de nada técnico y orienta los umbrales de todos los agentes.
- P3, compuerta antes de producción.** Cuando el conjunto de oro tenga volumen suficiente para que la compuerta signifique algo.
- P4, escala de madurez conectada a la API.** Antes de que el primer agente decida sin revisión previa, no después.
- P5, auditor.** En modo pasivo desde que exista P1; en modo activo cuando P2 y P3 estén en pie.
- D2 y D3, estados y reglas.** Avanzan aparte, sin esperar a ninguna de las seis.

Los riesgos de este enfoque

Nos parece honesto nombrar lo que puede salir mal con lo que estamos proponiendo, no solo lo que habilita.

Que la métrica se vuelva el objetivo

Cuando un número decide ascensos, el sistema tiende a optimizarlo a costa del resultado que representaba. Mitigación: una métrica de negocio siempre al lado de la técnica.

Que evaluar cueste más que ejecutar

Suites completas con repeticiones tienen costo real de cómputo. Mitigación: suite corta en cada cambio, completa en la promoción, y medir el costo de evaluar.

Que la instrumentación se sienta burocrática

Si capturar la corrección hace más lento el trabajo en preradicado, se llena mal. Mitigación: diseñarla con quienes la usan y medir cuánto tiempo agrega.

Que el conjunto de oro envejezca

Un conjunto que ya no representa el proceso aprueba lo que debería frenar. Mitigación: dueño explícito, refresco periódico y revisión ante señales de deriva.

Cómo proponemos revisar esto

Un chequeo rápido a las dos semanas de iniciadas P1 y P2, para detectar temprano si algo no encaja, y una revisión más completa al mes. Si al mes el catálogo de métricas no tiene fichas publicadas o el conjunto de oro no tiene dueño, eso no es un retraso de cronograma: es la señal de que el enfoque no está siendo adoptado, y conviene hablarlo de frente en lugar de esperar.

ANEXO A


Marco de decisión

Con qué criterio separamos lo que conviene acordar ahora de lo que puede quedar abierto.

Los acuerdos que pedimos en las seis propuestas son pocos a propósito. El criterio para incluir uno es que cumpla al menos una de tres condiciones: su costo de revertir es alto, su impacto trasciende a un solo equipo, o tiene implicaciones de seguridad y cumplimiento. Todo lo demás lo decide cada equipo sin pedir permiso.

Lo que endurece una decisión no es su naturaleza, es cuántos consumidores independientes construyen sobre ella y qué tan rápido crece ese número. En el diseño actual eso dejó de ser hipotético: la entrada por línea de negocio y los agentes expertos transversales garantizan que el esquema de eventos, la traza y el plano de control de IA tendrán múltiples consumidores. Un ejemplo del propio proyecto: elegir el tiempo de ejecución agéntico de un gestor era una decisión interna reversible, y con un tiempo de ejecución compartido en el plano de control de IA pasó a ser costosa de revertir, sin que la decisión cambiara.

Figura 7. Cuadrante de reversibilidad frente a impacto



Solo el cuadrante inferior derecho, costoso de revertir y con impacto entre equipos, justifica deliberación ahora.

LA PRUEBA DE UNA SOLA FRASE

Antes de cerrar un acuerdo, pedir que alguien explique en una frase por qué es costoso de revertir. Si nadie puede hacerlo con convicción, no pertenece a la agenda de arquitectura.

El segundo criterio separa dos tipos de problema que se tratan distinto. El diseño de un esquema de eventos o de un modelo de estados es **complicado**: la relación causa-efecto se puede analizar con experiencia experta y hay una respuesta razonable alcanzable con el análisis correcto. El comportamiento agregado de agentes no deterministas sobre un proceso real es **complejo**: la causa y el efecto solo se entienden en retrospectiva, y el camino es sondear en pequeño, observar y decidir con lo observado. Tratar lo complejo como complicado, con un gran análisis previo, es el error más costoso de los dos.

Figura 8. Los cuatro dominios de Cynefin aplicados a este proyecto



Tratar un problema complejo como si fuera complicado, con un gran análisis anticipado, es el error que Cynefin advierte evitar.

SUSTENTO La práctica documentada para el ciclo de vida de agentes recomienda buscar la solución más simple que resuelva la necesidad, y advierte que si un problema se resuelve con automatización tradicional, recuperación de información o una instrucción bien diseñada, la IA agéntica introduce complicaciones innecesarias. La separación que el equipo ya hizo entre reglas duras y agentes evaluadores es una aplicación directa de ese criterio.

ANEXO B

Cómo leemos su arquitectura

El nombre que la industria le da a lo que el equipo construyó, y qué se sigue de eso.

El Gestor de Solicitud es, en el vocabulario de la práctica documentada, una **arquitectura vertical jerárquica**: un agente de nivel alto interpreta y descompone, uno de nivel medio convierte objetivos en directivas y reparte, y varios de nivel bajo ejecutan tareas especializadas. Esto no es una observación académica: significa que se le pueden aplicar las mitigaciones conocidas de ese patrón.

Nivel	Pieza en el diseño	Responsabilidad
Alto	API orquestadora por tipo de solicitud	Interpreta la solicitud, determina el tipo y decide qué se necesita.
Medio	Receptor y enrutador de documentos	Valida que los archivos correspondan, identifica dónde está cada documento y reparte trabajo.
Bajo	Agentes extractores expertos	Cada uno especializado en un documento: historia clínica, orden, factura, otros.
Consolidación	Agente que arma la solicitud	Recibe el análisis de cada experto y construye la respuesta según el tipo.


LAS DOS DEBILIDADES CONOCIDAS DEL PATRÓN, Y QUÉ HACER

El líder es cuello de botella y punto único de fallo: si la API orquestadora o el enrutador se degradan, ningún experto puede trabajar por más sano que esté. Dos barandas concretas: presupuesto de tiempo propio por agente con degradación independiente, y ejecución en paralelo de los extractores, que además convierte la latencia del gestor en la del documento más lento y no en la suma de todos.

Sobre los componentes que toda arquitectura agéntica resuelve, percepción, planificación, memoria, razonamiento, herramientas, comunicación y aprendizaje, el diseño actual los cubre casi todos. Las brechas que vemos son tres, y las tres están atendidas por las propuestas: no hay política de memoria declarada ni versionada, no se mide el uso de herramientas, y el aprendizaje no tiene con qué verificarse mientras no exista conjunto de oro.

Para gestionar el conjunto proponemos separar cinco planos, porque cada uno responde una pregunta distinta y cambia a una velocidad distinta. La distinción más útil es que la **observabilidad** registra qué hizo el agente, la **evaluación** dice si estuvo bien, y el **plano de control** decide qué le está permitido. En el diseño actual la primera vive en la torre de control, la tercera en el plano de control de IA, y la segunda es la que todavía no tiene dueño.

Figura 9. Los cinco planos para gestionar el sistema agéntico




Los planos 2 y 3 se estandarizan una vez para todos los gestores; los planos 1 y 4 son propios de cada equipo, dentro de esas reglas.

El agente auditor pertenece al plano de evaluación, no al plano de ejecución del gestor que audita.

Y sobre el ritmo para sostener esto, proponemos dos cadencias y un solo lugar visible: un ritmo diario de identificación, donde arquitectura acompaña brevemente a los equipos para detectar acuerdos candidatos apenas aparecen, y un ritmo de decisión dos veces por semana, donde se cierran los identificados y se resuelven los cambios de nivel de madurez con un registro de una página. Sin poder de veto: se busca la mejor decisión con la información disponible, no un permiso.

Figura 10. Quién hace qué durante la semana: arquitecto frente a equipo de implementación



El arquitecto no interrumpe el trabajo diario; solo entra y sale brevemente, y decide con otros dos veces por semana.

El equipo de implementación nunca se detiene a esperar una decisión; el arquitecto entra a su ritmo, no al revés.

ANEXO C

Detalle de medición

Qué se mide en cada pieza, con qué fórmula, y qué obliga a volver a medir.

La acertividad se mide en tres alturas, y ninguna basta sola: **componente**, cada agente y herramienta por separado; **trayectoria**, el camino de razonamiento y de llamadas; y **extremo a extremo**, si la solicitud quedó lista o correctamente escalada. Un gestor puede acertar de punta a punta por un camino que no se sostiene con el siguiente documento, y eso solo lo detecta la medición de trayectoria.

Figura 11. Las tres alturas de medición sobre el flujo del Gestor de Solicitud



Las tres alturas se miden siempre juntas: una sola de ellas dice que algo pasó, pero no dice qué cambiar.

Las tres alturas no son alternativas entre sí, son capas de una misma medición.

Pieza	Métrica propuesta	Contra qué se compara
Receptor y enrutador	Tasa de clasificación correcta y matriz de confusión entre tipos de documento.	Tipo confirmado por un humano en la muestra revisada.
Extractores expertos	Acierto por campo, y proporción de campos con respaldo verificable en la fuente.	Campos etiquetados sobre el documento, con la ubicación de cada valor.
Armado de la solicitud	Validez de esquema, campos faltantes, campos sin respaldo.	El contrato hacia Evaluación, verificado automáticamente.
Compuerta y escalamiento	Dos números separados: cuánto de lo escalado era para humano, y cuánto de lo no escalado debía escalarse.	Desenlace real del caso, incluida la corrección humana.
Agentes evaluadores	Concordancia con la decisión humana, medida por separado para autorizar, negar y escalar.	Decisión humana registrada y desenlace posterior.
Gestor completo	Casos completados sin intervención, tiempo por caso, costo por caso y costo por caso correcto.	Desenlace real en el núcleo, incluido el retrabajo.
Agente auditor	Proporción de recomendaciones aprobadas que mejoran la métrica en la medición siguiente.	La medición del agente antes y después, sobre los mismos casos.

Conviene medir cuatro familias juntas, para que ninguna tape a las otras: **calidad**, como tasa de éxito de tarea y acierto de llamada a herramientas; **seguridad**, como violaciones de política o fuga de datos sensibles; **operación**, como latencia, consumo y costo por caso; y **negocio**, como retrabajo evitado o costo por resultado. Y una advertencia que aplica de lleno: elegir la fórmula concreta de

cada métrica es en sí misma una decisión de arquitectura, porque distintos métodos de cálculo producen incentivos operativos distintos.

Una métrica describe, una fitness function decide

Una fitness function es una prueba objetiva y automatizada que verifica que la arquitectura sigue cumpliendo una característica que importa. No verifica que una funcionalidad haga lo que el negocio pidió, sino que el sistema conserva una propiedad, y mide el resultado y no la implementación. La diferencia con una métrica es la consecuencia: la métrica dice que el acierto por campo fue de tanto por ciento; la fitness function dice que si la salida no cumple el contrato, este caso no avanza.

TRES ADVERTENCIAS

No todo se automatiza, y lo que requiere juicio humano conviene declararlo como manual en lugar de suponer que corre solo. Una fitness function que nadie ejecuta no existe: si la consecuencia de incumplirla es un correo que se puede ignorar, no es una baranda. Y vale más una sola sobre el esquema de eventos, que es costoso de revertir, que diez sobre detalles internos de un equipo.

Errores de extracción verificables con reglas

Para el uso de herramientas existe una taxonomía de errores que se verifica sin juicio, y que sirve tal cual como batería de pruebas de un agente extractor: campo que no existe en el esquema, campo obligatorio ausente, tipo de valor incorrecto, valor fuera del catálogo permitido, y parámetro alucinado. A eso se suman dos verificaciones semánticas: que cada valor se derive del documento o del contexto, y que las conversiones de formato sean correctas.

Qué obliga a volver a medir

- **Cambió la mezcla de entrada:** un tipo de documento nuevo, un prestador con otro formato, un canal que sube imágenes en vez de PDF.
- **Cambió alguna de las cuatro partes del agente:** prompt, modelo, herramienta o política de memoria, incluida una actualización menor del modelo en uso.
- **Subió la tasa de escalamiento sin explicación:** suele ser la primera señal de deriva, porque el agente se vuelve inseguro antes de volverse incorrecto.
- **Bajó la consistencia entre corridas** para el mismo caso.
- **Ocurrió un incidente atribuible a una decisión del agente:** aquí la re-evaluación no es opcional, y conviene acompañarla de un descenso temporal de nivel.

Estos disparadores deberían ser alertas sobre la torre de control y no un punto en la agenda de una reunión. En la misma línea, conviene tener definidos desde el inicio tres mecanismos de contención: desactivar un agente de inmediato, volver a la versión anterior sin reconstruir nada, y cortar el acceso de un agente a una herramienta sin tumbar el gestor completo.

SOBRE USAR UN MODELO COMO JUEZ

Será necesario para evaluar lo que no se puede verificar con reglas, por ejemplo si una extracción está bien fundamentada en el documento. Es legítimo y es la única forma de evaluar a escala, pero hay que calibrarlo: medir sobre una muestra qué tanto coincide con la persona experta, y reportar ese nivel de coincidencia junto a cualquier métrica que dependa de él. El modelo juez trabaja con los evaluadores humanos, no los sustituye.

ANEXO D

Sustento

De dónde viene cada afirmación de este documento.

Diseños del equipo, fuente primaria

- *Arquitectura-Gestores.drawio*, ocho vistas, incluidas Arq gestores V2, Gestor de monitoreo, Detalle, Gestor de finalización y Resumen.
- *Arquitectura-Gestores-General Transversal.drawio*, vista general multi-línea de negocio.

Práctica documentada, IBM Think

- Arquitectura agéntica, tipos de arquitectura y factores de agencia. ibm.com/es-es/think/topics/agentic-architecture
- Componentes de los agentes de IA. [components-of-ai-agents](#) · Agentes jerárquicos. [hierarchical-ai-agents](#) · Sistemas multiagente y sus desafíos. [multiagent-system](#)
- Flujos de trabajo agénticos y orquestación. [agentic-workflows](#) · [ai-agent-orchestration](#)
- Plano de control de agentes, y la diferencia entre medir y permitir. [agent-control-plane](#)
- Evaluación de agentes, familias de métricas y métricas de llamada a funciones. [ai-agent-evaluation](#)
- Pruebas de agentes: componente, trayectoria y extremo a extremo, conjuntos balanceados y simulación de entornos. [ai-agent-testing](#)
- AgentOps y telemetría abierta. [agentops](#) · Ciclo de vida de desarrollo de agentes. [agent-development-lifecycle-adlc](#) · Gestión del ciclo de vida. [agent-lifecycle-management](#)
- Gobierno de agentes, agentes de gobierno y mecanismos de contención. [ai-agent-governance](#) · Seguridad. [ai-agent-security](#) · Proliferación. [ai-agent-sprawl](#)
- Llamada a herramientas y memoria. [tool-calling](#) · [ai-agent-memory](#) · Agentes de IA en sanidad. [ai-agents-healthcare](#)
- Tutoriales consultados para el detalle práctico: evaluación, observabilidad con trazas y refinamiento a partir de lo observado, telemetría, human-in-the-loop y agente listo para producción. [evaluación](#) · [observabilidad](#) · [telemetría](#) · [human-in-the-loop](#) · [producción](#)

Literatura de arquitectura y organización

- Ford, Parsons, Kua. *Building Evolutionary Architectures*. Fitness functions automatizadas en el pipeline.
- Skelton, Pais. *Team Topologies*. IT Revolution, 2019.
- Thoughtworks Technology Radar. Proceso de asesoría de arquitectura. [thoughtworks.com](https://www.thoughtworks.com)
- Poppendieck, último momento responsable; y la distinción entre decisiones de una vía y de dos vías, carta a los accionistas de Amazon, 1997.
- Snowden, Boone. Marco Cynefin.

Este documento recoge la lectura profesional de Tech and Solve sobre el diseño vigente y la evidencia disponible en esta etapa. Cada propuesta es un punto de partida para la discusión: queda al criterio del equipo de SURA adoptarla, ajustarla o descartarla.